Rapport Séries Temporelles

Patricio Silva

Contenus

1. Intruduction
2. Objectif du projet
3. Statistiques déscriptives
4. ARMA
    1. Étude des résidus
    2. Résponse impulsionnnellle
    3. Statistique Q
5. GARCH
    1. Comparaison
    2. Diagnostique du modèle
6. Racines unitaires
7. VAR
8. Coïntégration
9. Anexe: Code

Introduction

La série temporelle à étudier pour ce projet est la variation mensuelle de l'IPC en France métropolitaine entre janvier 1996 et décembre 2025, ce qui donne une série de 360 observations mensuelles.

Cette variation de l'IPC correspond à l'inflation sous-jacente hors produits volatils ou régulés tels que l'énergie, le tabac, etc. Ce groupe de produits correspond au code 4035 de l'INSEE après avoir été contrôlés pour les effets saisonniers.

Les données ont été récupérées depuis ce site de l'INSEE.

Pour la suite, d'autres séries seront considérées pour les modèles multivariés. Comme rappel, la variation de l'IPC est calculée avec l'expression ci-dessous : $$ \dfrac{IPC_{t} - IPC_{t-1}}{IPC_{t-1}} \cdot 100 \quad [%] $$ ce qui donne un pourcentage de variation par rapport à la valeur précédente.

Objectif du projet

Le but de ce projet est d'étudier cette série avec des modèles statistiques, ainsi que de comparer ses résultats avec d'autres observations.

Statistiques descriptives

Tout d'abord, le graphique de la série temporelle en fonction du temps est montré ci-dessous :

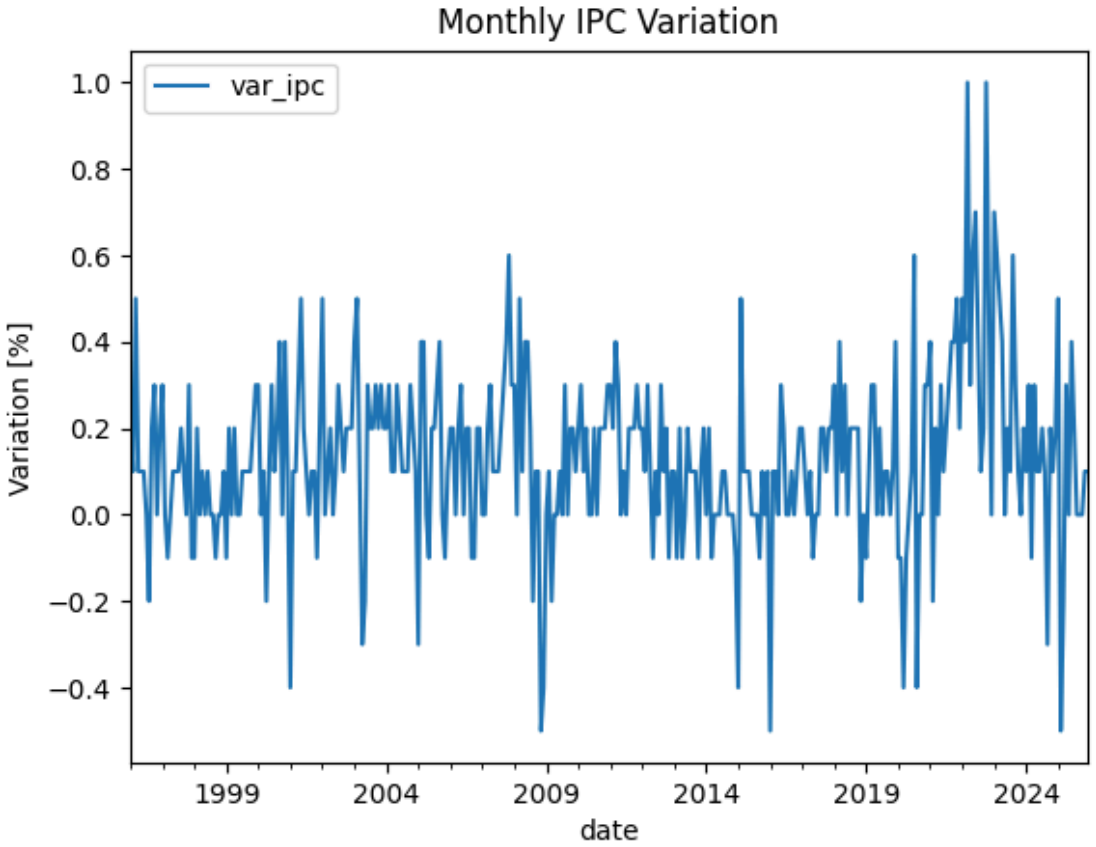

ce qui ressemble au comportement attendu : une série sans tendance ni saisonnalité apparente, avec un bruit considérable autour de la moyenne.

La distribution des données est mieux appréciée sur son histogramme

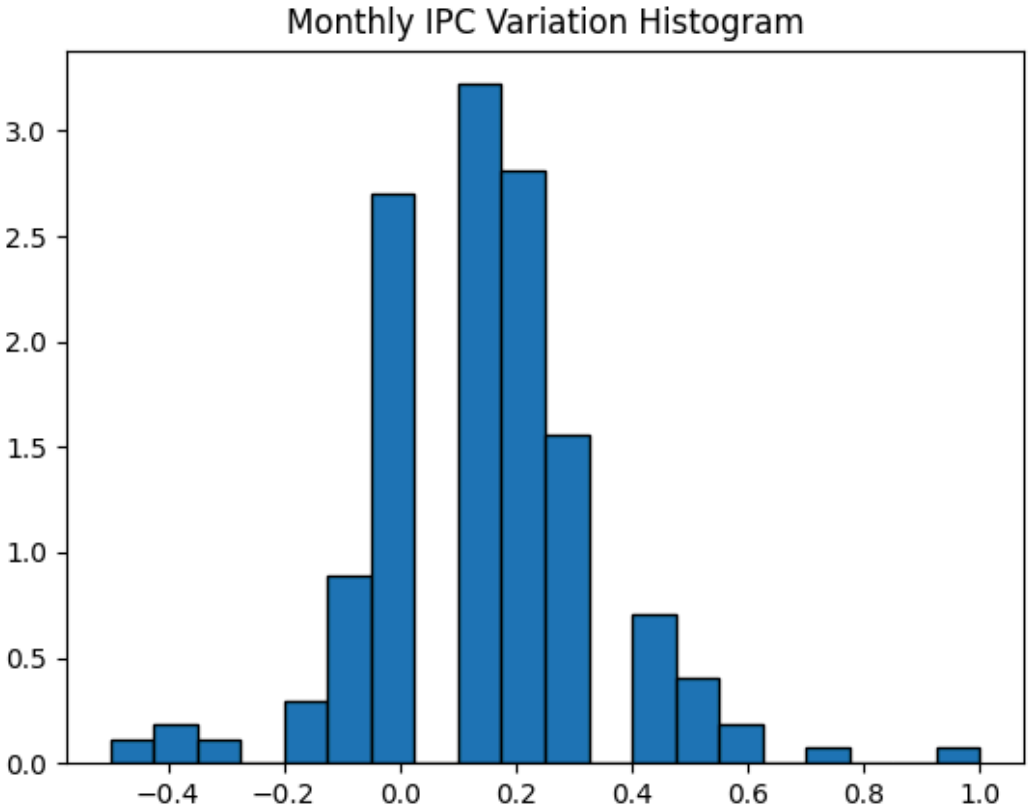

où les données semblent se concentrer autour de zéro, avec une distribution assez symétrique, avec certaines valeurs sous-représentées. Avec l'estimateur à noyau (*Kernel Density*) de sklearn, la densité sous-jacente peut être estimée, donnant la courbe de la figure suivante :

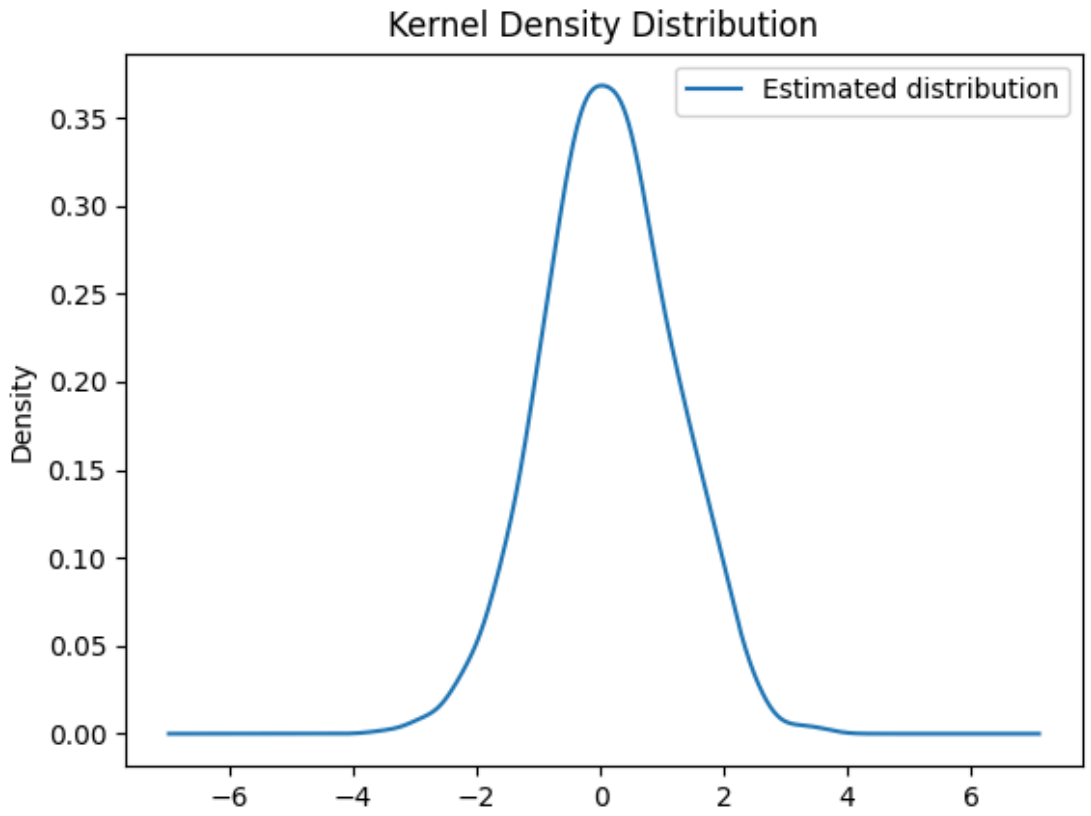

qui ressemble au comportement attendu des données, avec une variance assez faible.

Ensuite, les mesures statistiques des données sont présentées dans le tableau suivant :

Mesure	Valeur
count	360.0
mean	0.1322222222222222
std	0.19990403144739186
min	-0.5
25%	0.0
50%	0.1
75%	0.2
max	1.0
median	0.1
skewness	0.2790459386191692
kurtosis	2.40494439800041

Ce qui nous informe d'une distribution assez similaire à la gaussienne, avec des queues plus légères, sauf quelques valeurs élevées.

Ensuite, la fonction d'autocorrélation et l'autocorrélation partielle sont visibles ci-dessous :

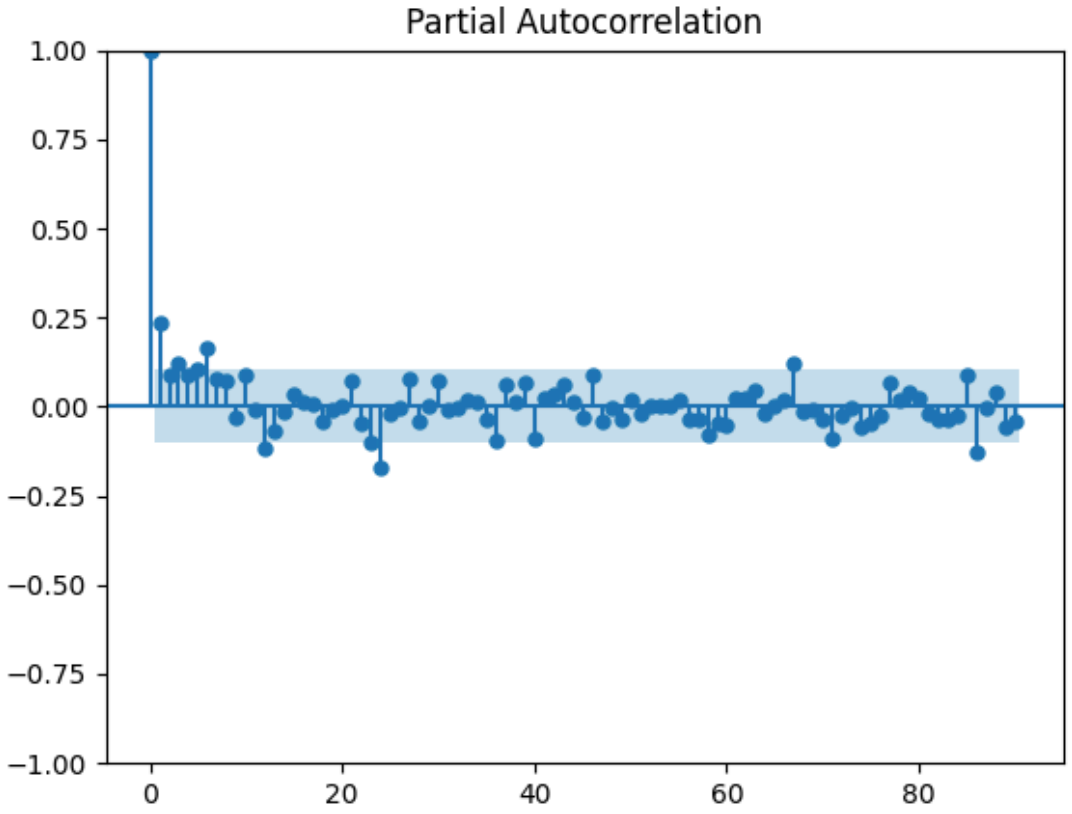

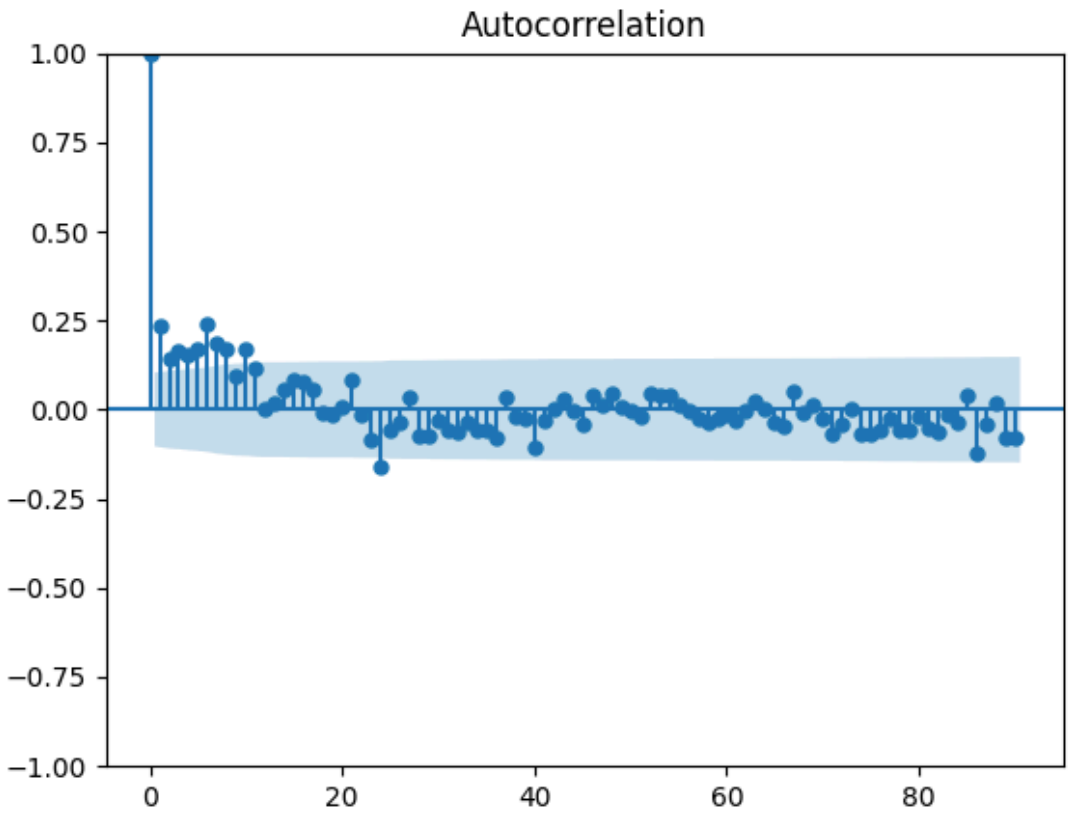

ce qui montre une faible autocorrélation qui décroît rapidement vers zéro et reste dans l'intervalle de confiance, sans évidence observable d'effets saisonniers, ce qui montre uniquement une certaine dépendance à court terme. Cela nous amène à la modélisation avec ARMA.

ARMA

Pour la suite, des modèles ARMA ont été estimés avec $p,q\in{0,1,2,3}$ et leurs p-values ont été consignées dans le tableau suivant :

coefficient	**0,0**	**0,1**	**0,2**	**0,3**	**1,0**	**1,1**	**1,2**	**1,3**	**2,0**	**2,1**	**2,2**	**3,0**	**3,1**
const	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
sigma2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
ma.L1		0.0	0.0	0.0		0.0	0.0	0.0		0.0	0.65		0.0
ma.L2			0.103	0.064			0.468	0.152			0.454		
ma.L3				0.045				0.106					
ar.L1					0.0	0.0	0.0	0.0	0.0	0.0	0.491	0.0	0.0
ar.L2									0.067	0.548	0.53	0.211	0.181
ar.L3												0.008	0.16

Les modèles qui n'ont pas convergé ont été omis. Les modèles situés à droite d'ARMA(1,1), ainsi qu'ARMA(0,2) et ARMA(0,3), présentent un ou plusieurs coefficients non significatifs, ce qui nous amène à considérer les modèles ARMA(0,0), ARMA(0,1), ARMA(1,0) et ARMA(1,1). Pour les comparer, les valeurs des critères AIC et BIC ont été obtenues et sont montrées ci-dessous :

Modèle	**AIC**	**BIC**
0,0	-134.50651353848326	-126.73430547558294
0,1	-149.81847236017805	-138.16016026582759
0,2	-150.46227825324894	-134.9178621274483
0,3	-152.27654642179414	-132.84602626454335
1,0	-152.99696973029992	-141.33865763594946
1,1	-170.83749535392812	-155.2930792281275
1,2	-169.30523557059814	-149.87471541334736
1,3	-169.7092607331736	-146.39263654447268
2,0	-153.9667387805323	-138.42232265473166
2,1	-169.22153143814103	-149.79101128089025
2,2	-167.9545733427326	-144.63794915403167
3,0	-157.45586297665375	-138.02534281940297
3,1	-169.38914123058737	-146.07251704188644

Selon le critère AIC, le modèle ARMA(1,1) est le meilleur, ce qui coïncide avec le résultat du BIC ; ce modèle sera donc considéré pour la suite.

Les inverses des racines du modèle sont 0.92473456 (AR) et 0.79524914 (MA), ce qui met en question la stationnarité de la série, et devra être étudié par la suite.

Étude des résidus

Pour vérifier la stationnarité de la série, la PACF et l'ACF ont été obtenues pour les résidus du modèle, donnant les

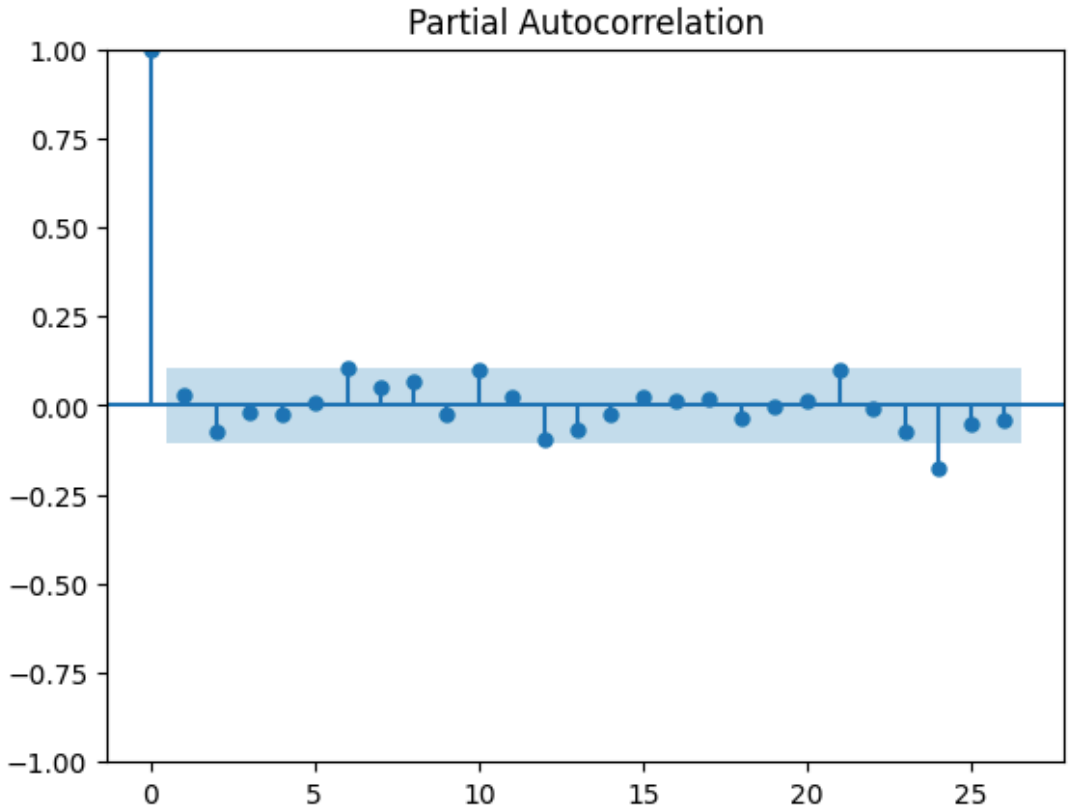

figures ci-dessous :

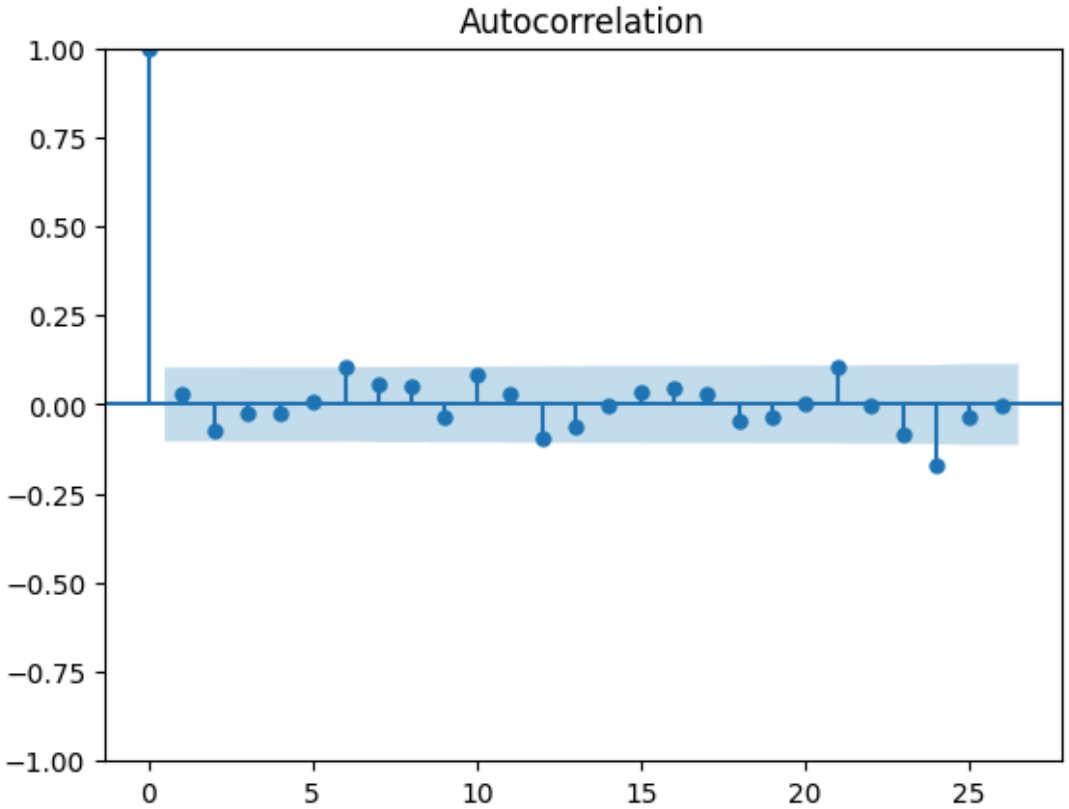

ce qui montre que les autocorrélations semblent rester dans l'intervalle de confiance, ce qui est cohérent avec l'hypothèse de bruit blanc. Il y a une petite valeur d'autocorrélation vers 24 décalages, mais cela semble être plutôt produit du bruit qu'une indication d'une autocorrélation significative.

Réponse impulsionnelle

D'après l'étude de la fonction de réponse sur la figure suivante, l'impulsion montre une mémoire courte, où le choc décroît vers zéro rapidement ; les chocs ne persistent donc pas dans le temps.

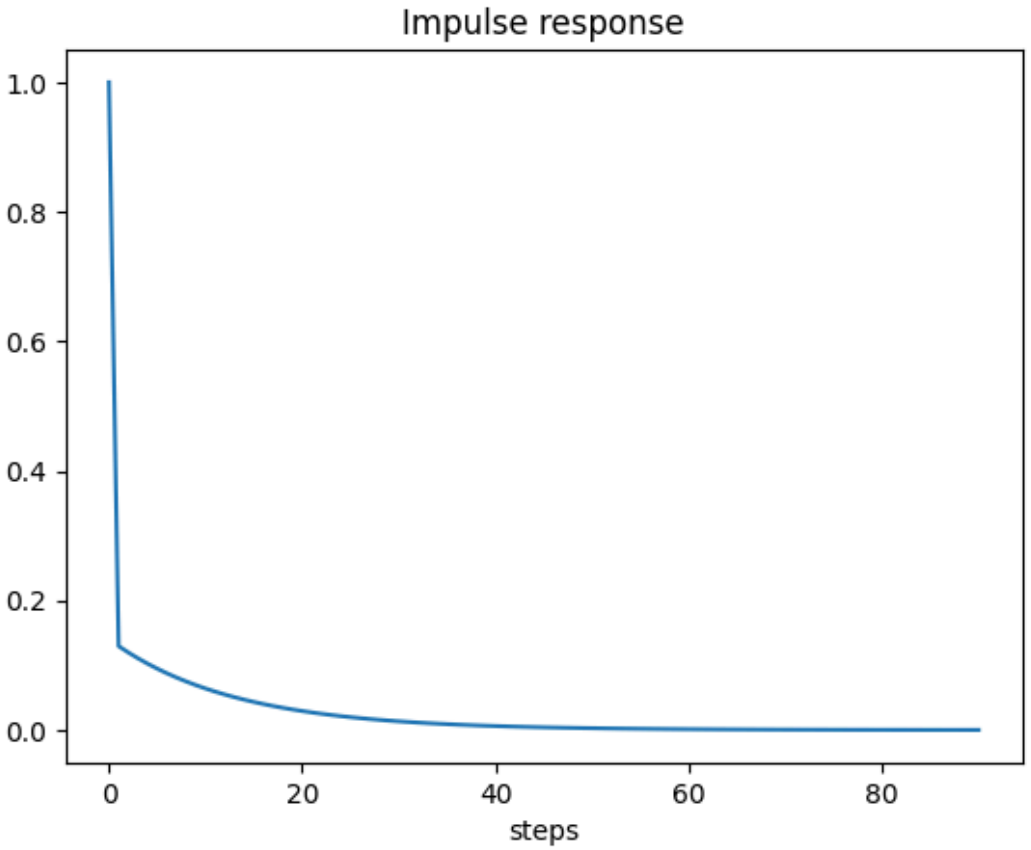

Statistique Q

Si le test d'hypothèse d'autocorrélation par la statistique Q est calculé, les p-values obtenues sont celles du tableau suivant :

lag	pvalue
1	0.604093
2	0.331133
3	0.492176
4	0.627785
5	0.756833
6	0.328794
7	0.332176
8	0.340709
9	0.395096
10	0.281037

On obtient que l'hypothèse nulle ne peut pas être écartée, d'où l'on conclut que les résidus ne sont pas autocorrélés.

Finalement, on visualise les valeurs ajustées pour étudier si la tendance a été bien captée par le modèle :

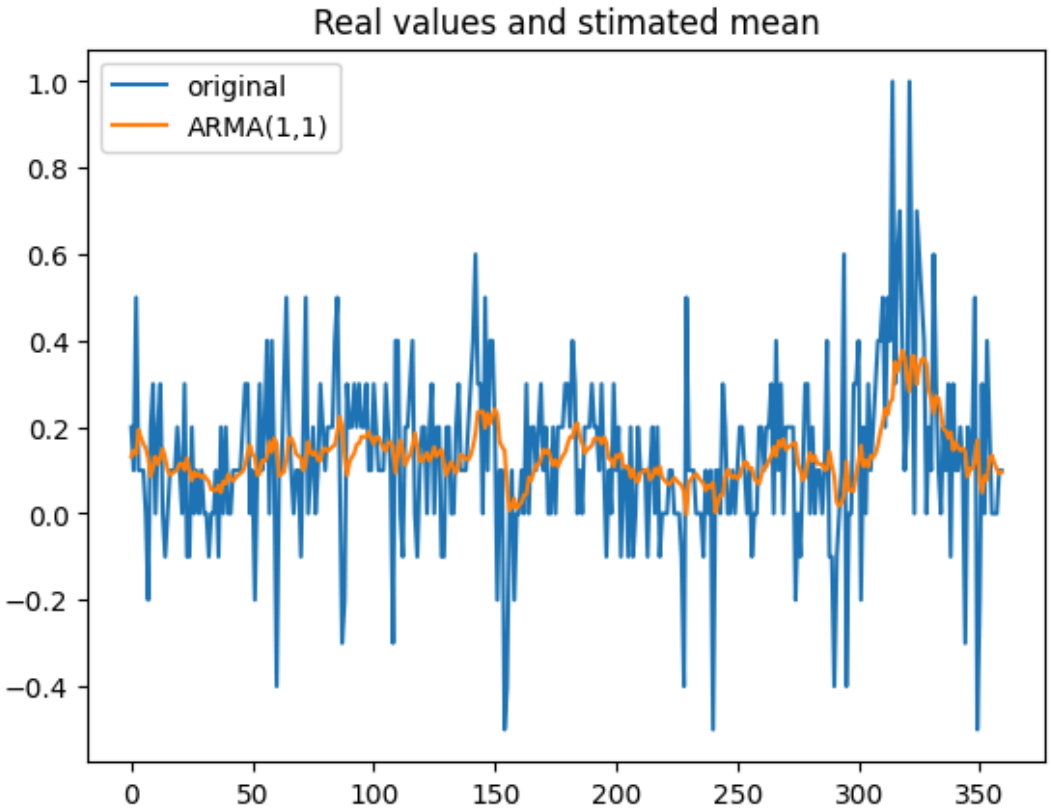

où l'on voit que la tendance est bien captée par le modèle. Ensuite, les résidus du modèle (ci-dessous) ressemblent à du bruit blanc, ce qui est cohérent avec les études réalisées.

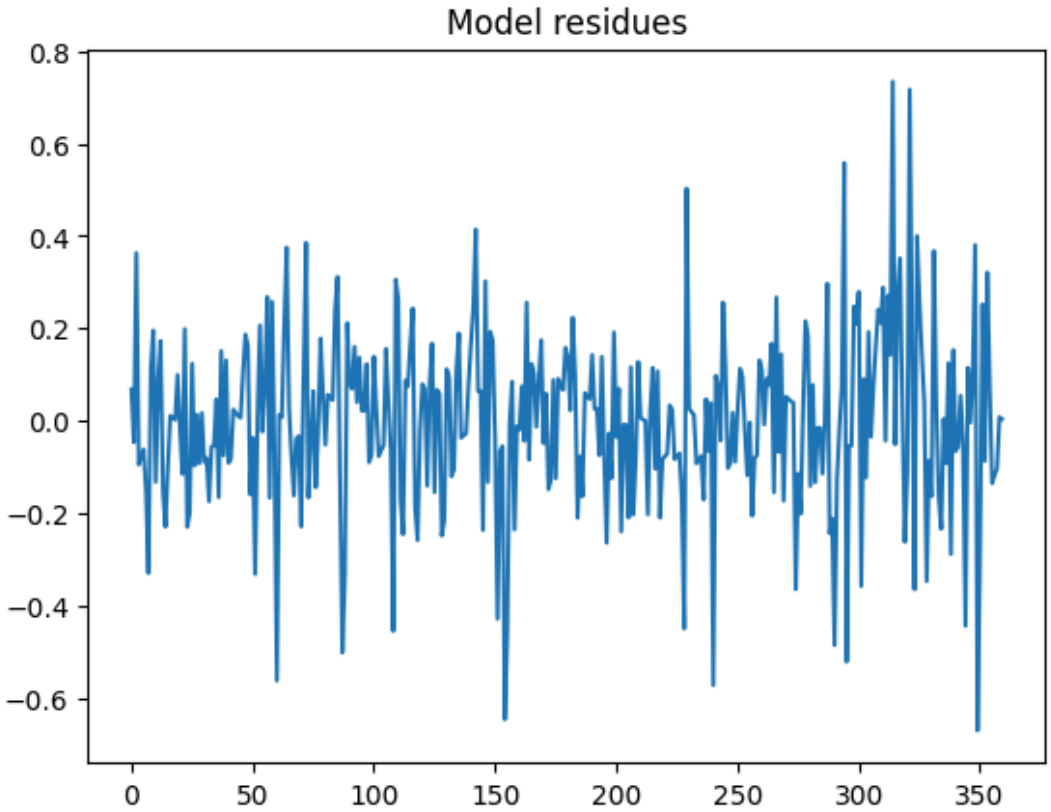

Étant donné que les graphiques précédents ne sont pas très différents, les valeurs, la moyenne estimée et les résidus ont été représentés ci-dessous pour plus de clarté :

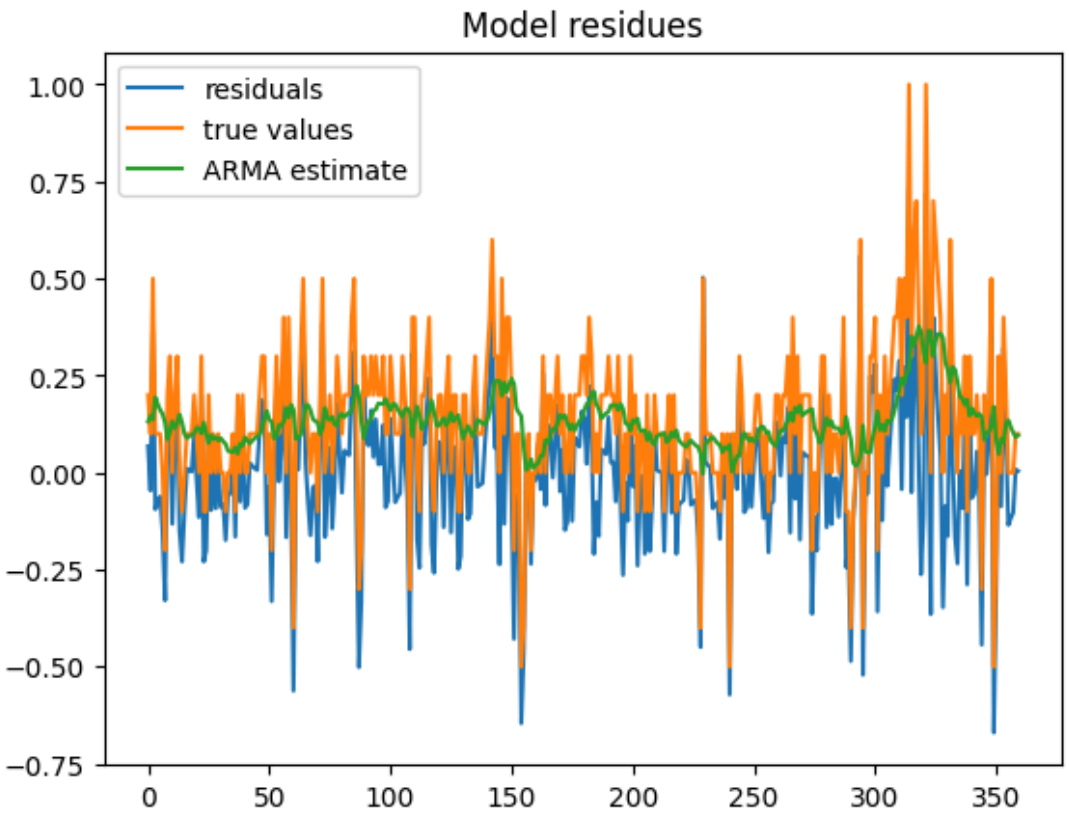

GARCH

À titre de référence, on essaie tout d'abord un modèle GARCH sur les données pour évaluer l'apport du modèle ARMA précédent. Dans un premier temps, les p-values des coefficients du modèle semblent être significatives :

coeff	p-value
omega	8.325067e-02
alpha[1]	3.855780e-03
beta[1]	4.168697e-25

En revanche, celles du GARCH estimé sur les résidus du modèle ARMA(1,1) ne semblent pas toutes aussi significatives :

coeff	pvalue
omega	0.217991
alpha[1]	0.102603
beta[1]	0.000001

Néanmoins, pour une comparaison correcte, les critères AIC et BIC doivent être considérés :

model	AIC	BIC
garch-base	-57.88096441526536	-46.22265232091489
garch-arma	-190.72818867476323	-179.06987658041277

ce qui montre que le modèle ARMA précédent est significatif et que les modèles GARCH pour la suite seront estimés sur ses résidus. En étudiant les coefficients obtenus dans le tableau ci-dessous, on peut voir que la somme est bien inférieure à 1, ce qui confirme l'hypothèse de stationnarité.

coeff	value
omega	0.004616
alpha[1]	0.116884
beta[1]	0.757214

Comparaison

Ensuite, le GARCH a été estimé avec les distributions t de Student et GED. Le tableau de comparaison des p-values ci-dessous montre que les coefficients sont bien plus significatifs pour les distributions non gaussiennes.

coeff	gaussian	t-student	GED
omega	0.217991	7.350181e-02	1.229680e-01
alpha[1]	0.102603	6.512143e-02	7.979812e-02
beta[1]	0.000001	4.068092e-07	3.843835e-07
nu	NaN	9.926439e-06	1.824966e-29

Pour le choix du modèle, les critères AIC et BIC sont montrés ci-dessous :

criterion	gaussian	t-student	GED
AIC	-190.728189	-210.508049	-207.116110
BIC	-179.069877	-194.963633	-191.571694

On conclut donc que la meilleure distribution est la t de Student. Bien que les coefficients de omega et alpha ne soient pas significatifs au seuil de 5 %, ils le sont à 10 %, ce qui apporte une indication de la validité du modèle. Avant de considérer l'utilisation d'IGARCH, les coefficients doivent être vérifiés :

coeff	value
omega	0.006282
alpha[1]	0.135997
beta[1]	0.699297
nu	5.220113

La somme entre alpha et beta n'est pas proche de 1, ce qui ne nous donne pas de motivation pour l'estimation d'IGARCH.

Diagnostic du modèle

Pour le diagnostic du modèle, plusieurs graphiques sont proposés. Tout d'abord, les résidus standardisés sont visualisés ci-dessous. Ceux-ci ressemblent à du bruit blanc, comme attendu.

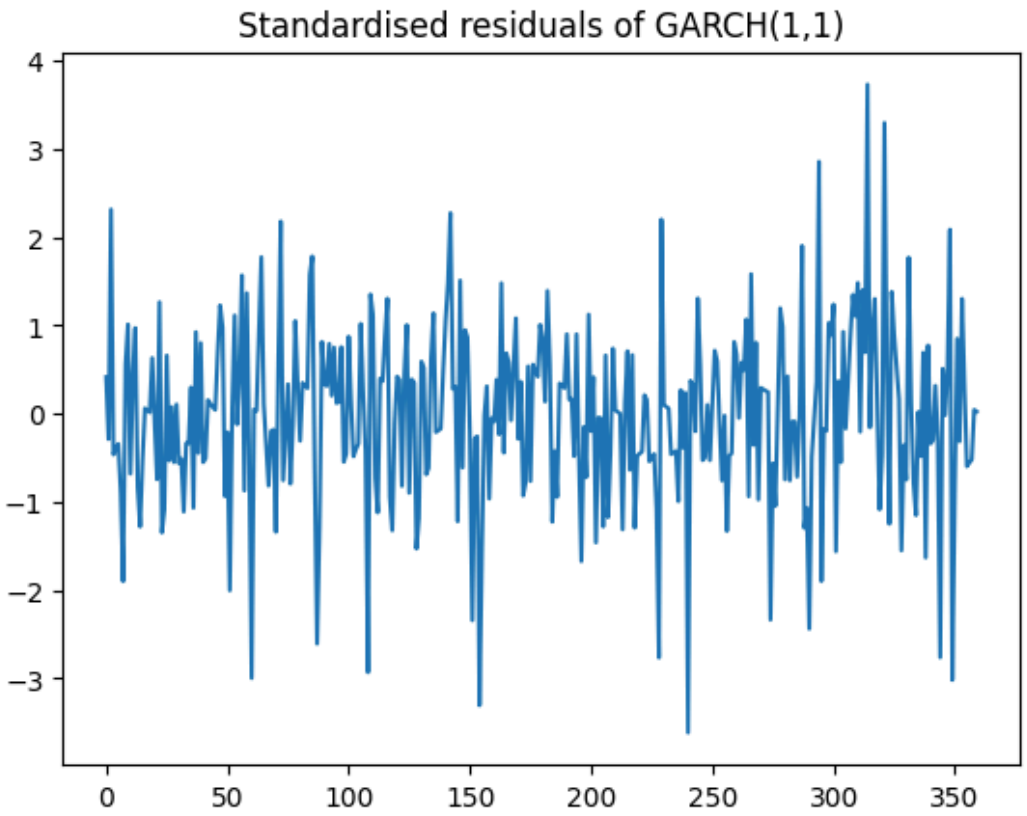

Ensuite, l'écart-type conditionnel est aussi représenté :

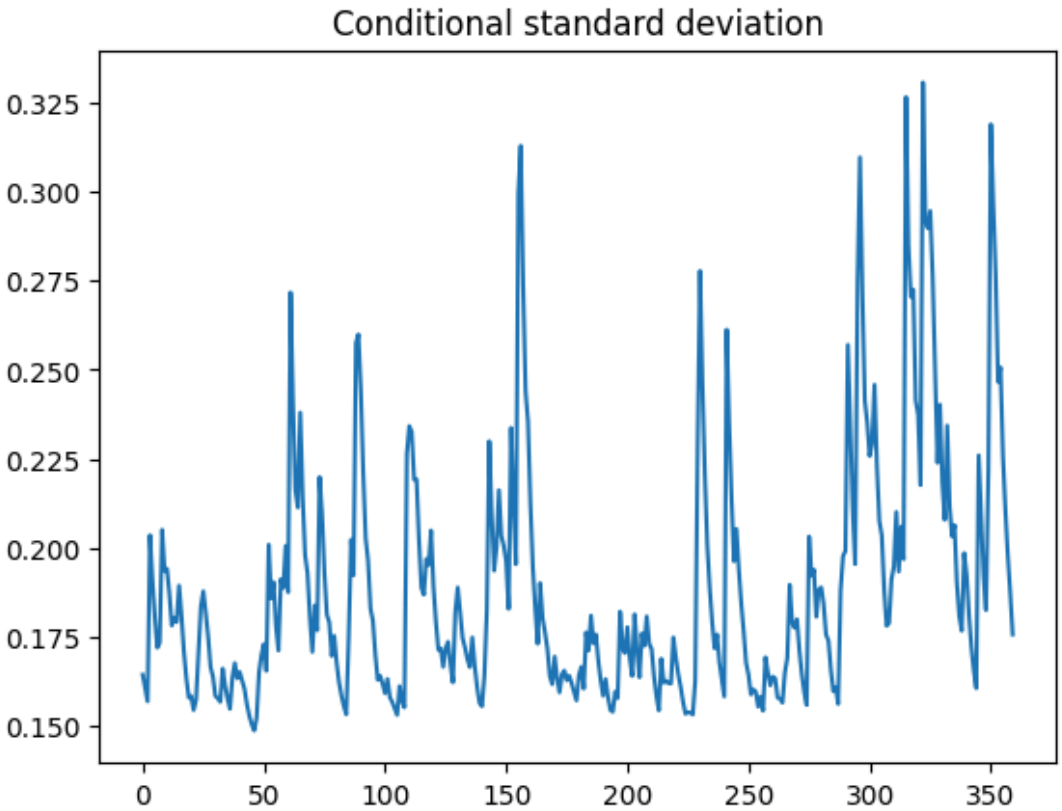

Ceci montre le comportement attendu : des regroupements de variance avec un retour à la moyenne, ce qui est conforme aux hypothèses du GARCH.

Puis, les autocorrélations des résidus standardisés sont tracées, où l'on peut s'apercevoir qu'il n'y a pas d'autocorrélation apparente :

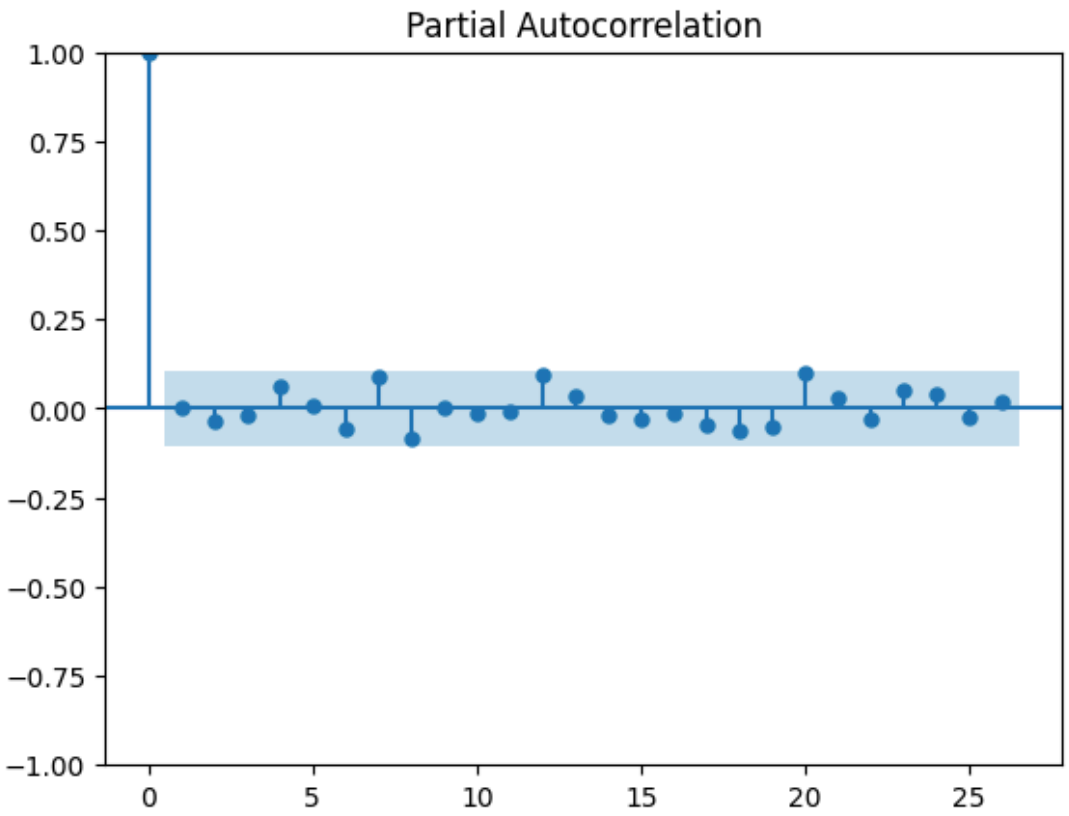

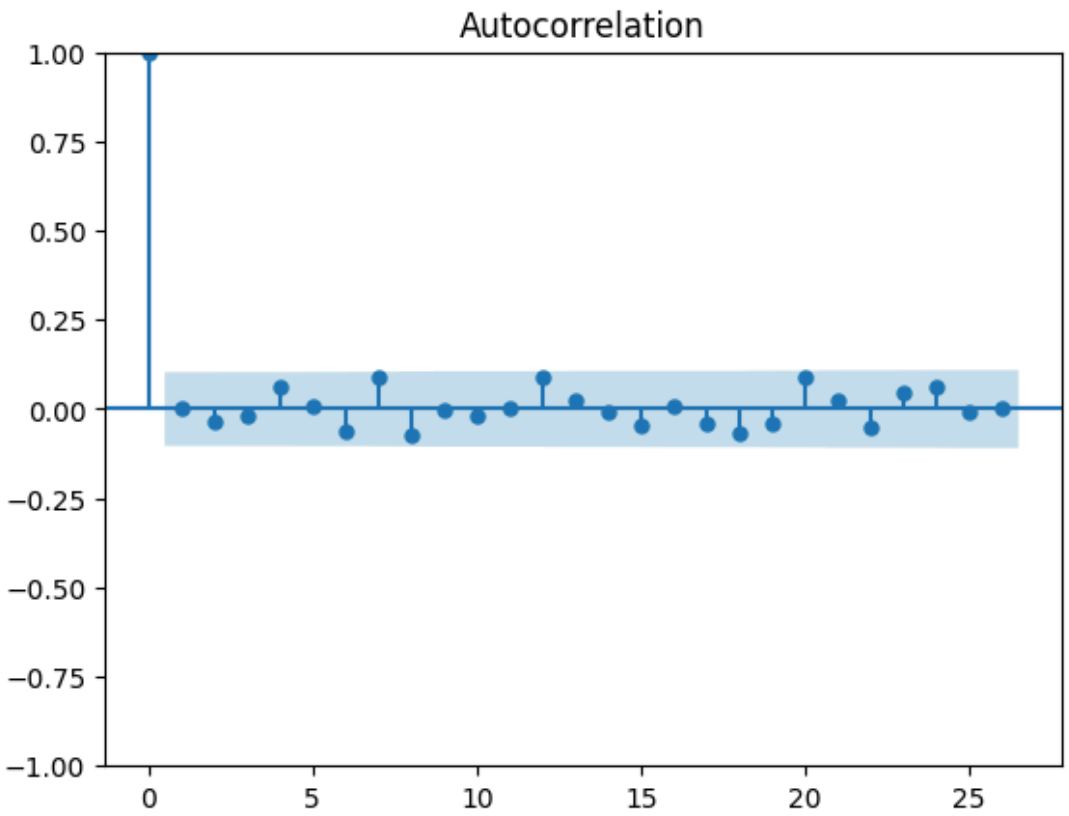

Ceci montre qu'il n'y a pas d'effet GARCH résiduel, ce qui témoigne d'une bonne spécification du modèle. D'après cette évaluation, les résidus standardisés devraient suivre une distribution bien ajustée à celle d'une t de Student, ce qui est montré sur

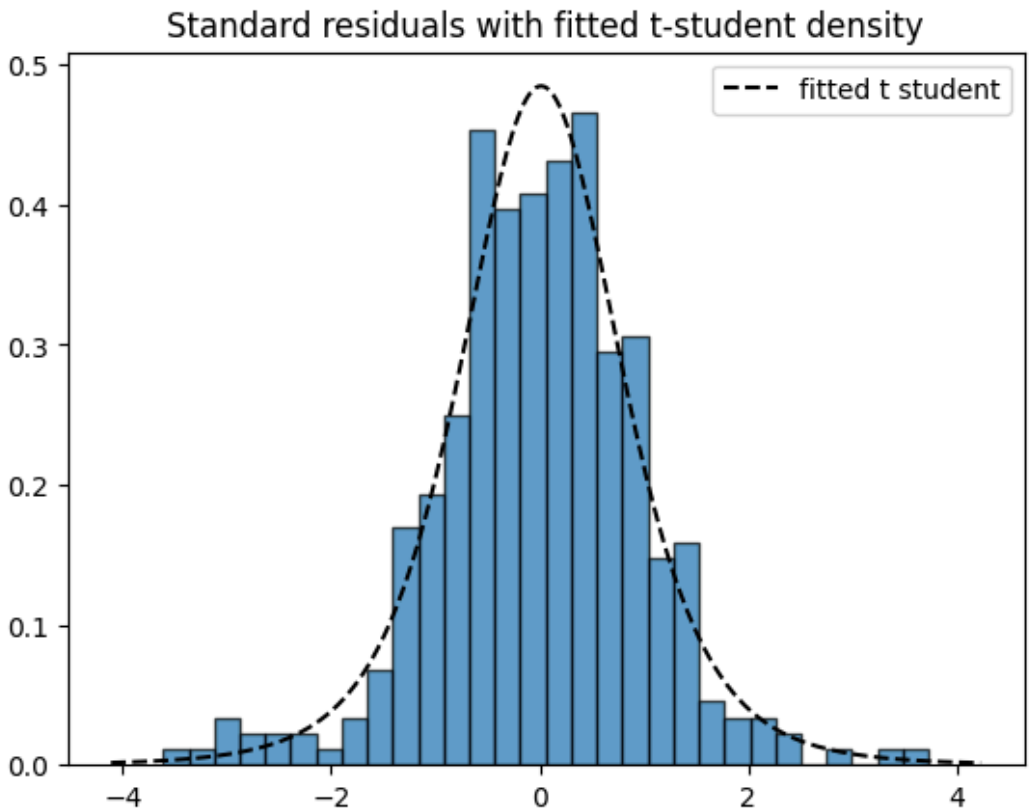

la figure suivante. Ainsi, la distribution ajustée présente un $\nu = 5.2$, ce qui montre que la distribution t de Student modélise les résidus standardisés mieux que la gaussienne.

Ensuite, le test GARCH (LM) a été réalisé sur les résidus standardisés, mais au préalable sur les résidus de l'ARMA, afin de vérifier que le phénomène GARCH était bien présent et qu'il a été bien capturé par le modèle GARCH :

model	p-value
ARMA	0.0037
ARMA + GARCH	0.59

Ceci montre une forte indication de la présence du phénomène et de sa bonne capture par le modèle estimé.

Racines unitaires

D'après les observations ci-dessus, il n'y a pas d'indication de non-stationnarité de la série jusqu'à ce point, mais il convient néanmoins de le vérifier. Pour cela, on utilise le test de Dickey-Fuller augmenté (ADF), qui donne une p-value de 0.0001 ; on rejette donc nettement l'hypothèse nulle : il n'y a pas d'indication d'une racine unitaire.

Pour une analyse plus complète, on teste plusieurs versions du test, selon le contrôle des tendances :

regression	p-value
none	0.0205
constant	0.000
constant and trend	0.000
constant and trend and quadratic trend	0.003

Ce qui montre définitivement qu'il n'y a pas d'indication de la présence d'une racine unitaire, quelle que soit la tendance considérée. Cela indique qu'il n'y a pas de raison de différencier la série, étant donné qu'elle est déjà stationnaire. Ceci valide également l'analyse précédente.

VAR

Pour la suite, on prend la variation mensuelle des aliments : aliments hors produits frais (ASFP) et produits frais (FP). La série précédente n'est pas appropriée pour une analyse multivariée car c'est la seule mesure corrigée des effets saisonniers dans les données, et les autres groupes de produits y sont inclus.

Les graphiques des nouvelles variables sont montrés ci-dessous :

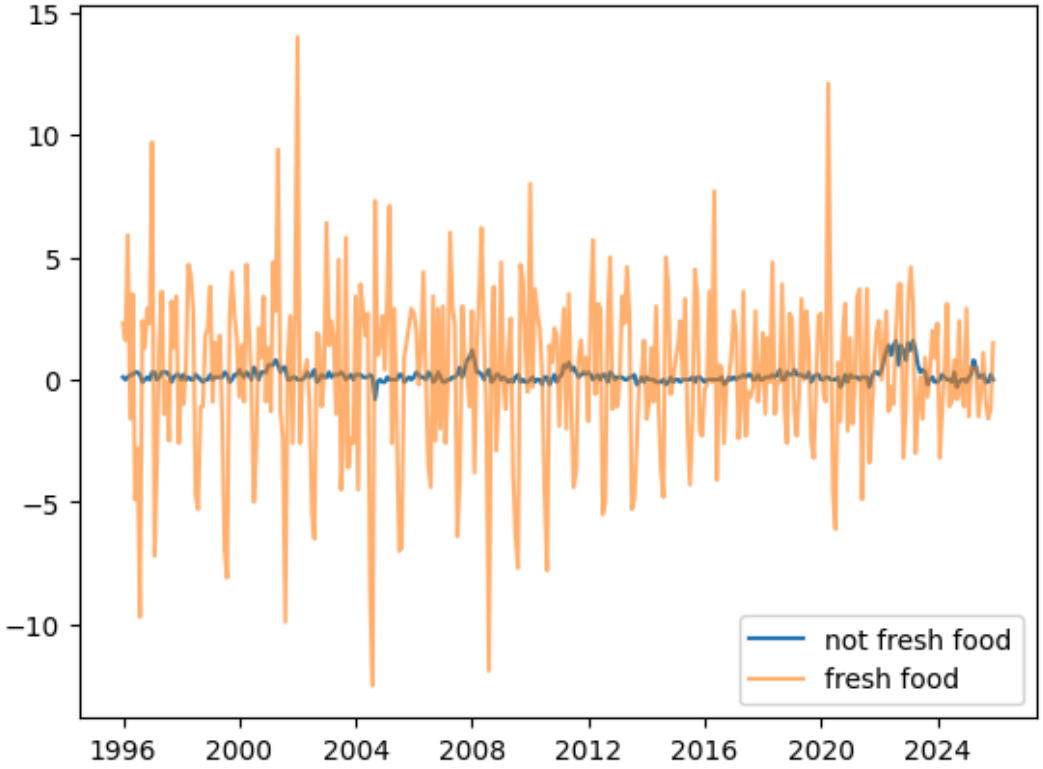

où il est possible d'observer que ces courbes suivent une certaine tendance commune, mais les produits frais présentent une variation bien plus élevée. Avec 360 observations, soit 30 ans, cela est facilement explicable par les variations saisonnières, ainsi que par des facteurs liés à la production en temps réel de ces produits.

A priori, la saisonnalité ne sera pas traitée : une approche agnostique. Tout d'abord, il faut vérifier que les composantes soient stationnaires, ce qui est réalisé avec le test ADF :

variable	p-value
ASFP	1.867874e-04
FP	4.492215e-09

Ceci montre qu'il n'y a pas d'indication de racines unitaires, pour lesquelles les composantes seront supposées stationnaires pour la suite. Néanmoins, les PACF et ACF sont tout de même étudiées. Les PACF de l'ASFP et du FP sont montrées ci-dessous (dans cet ordre) :

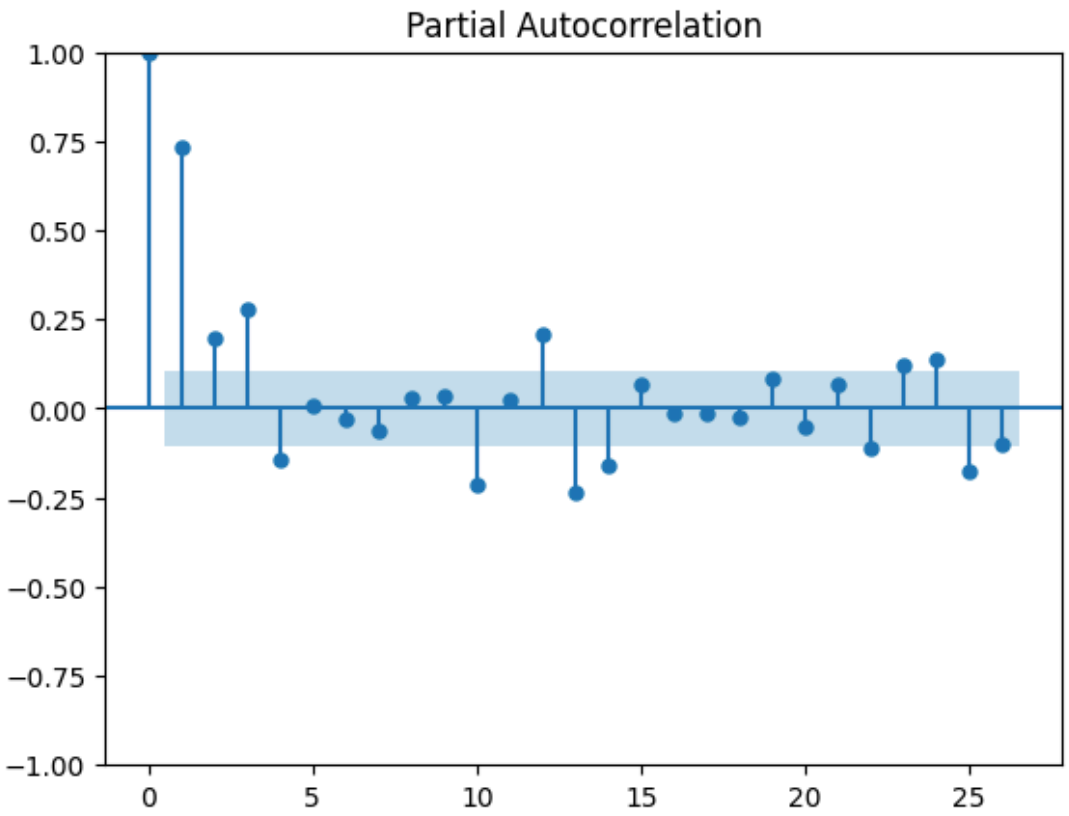

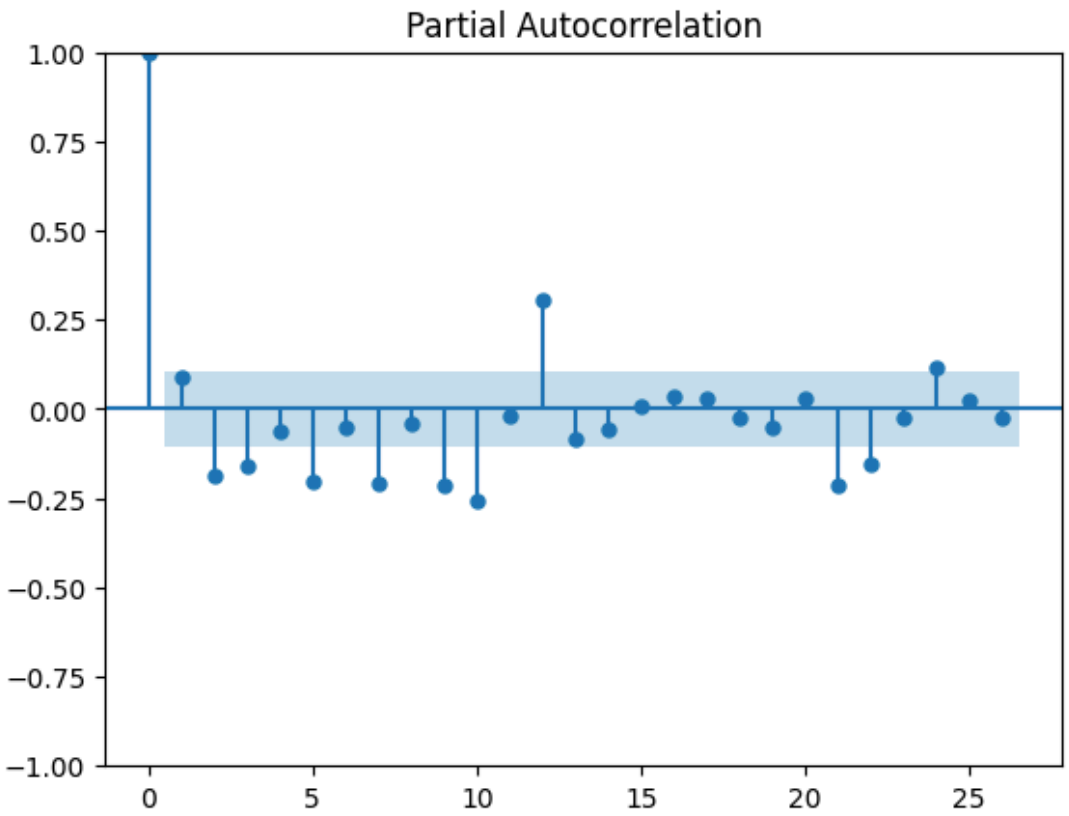

et celles de l'ACF :

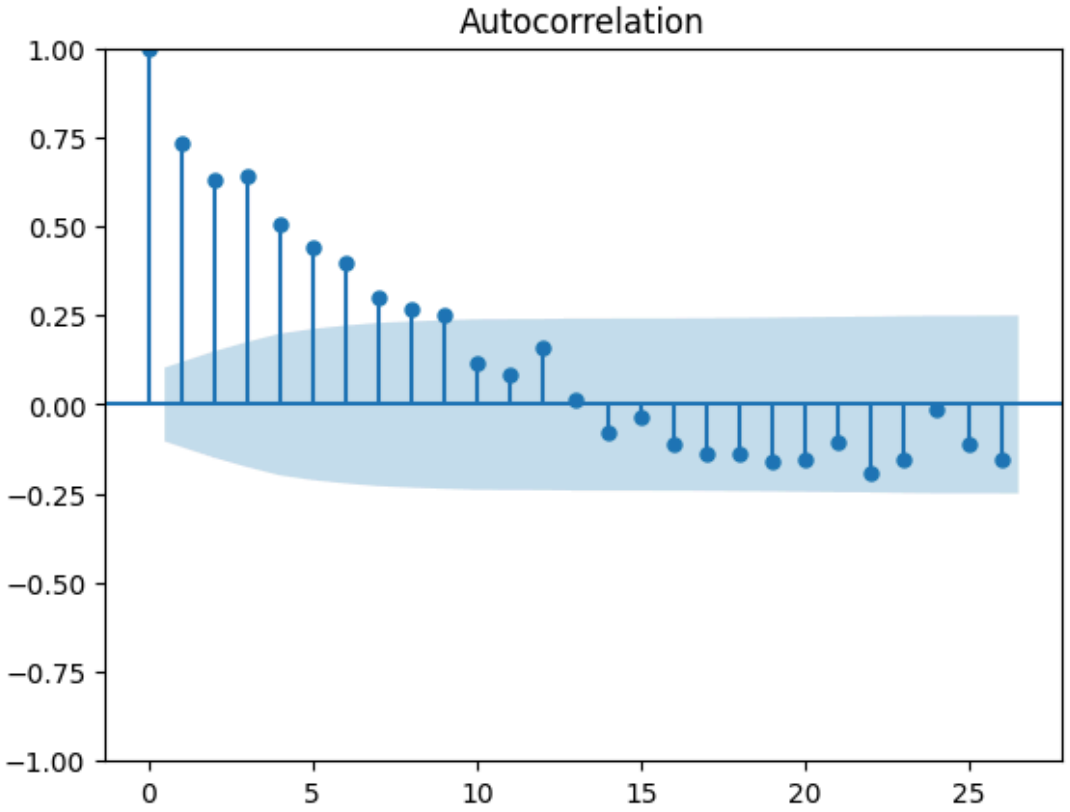

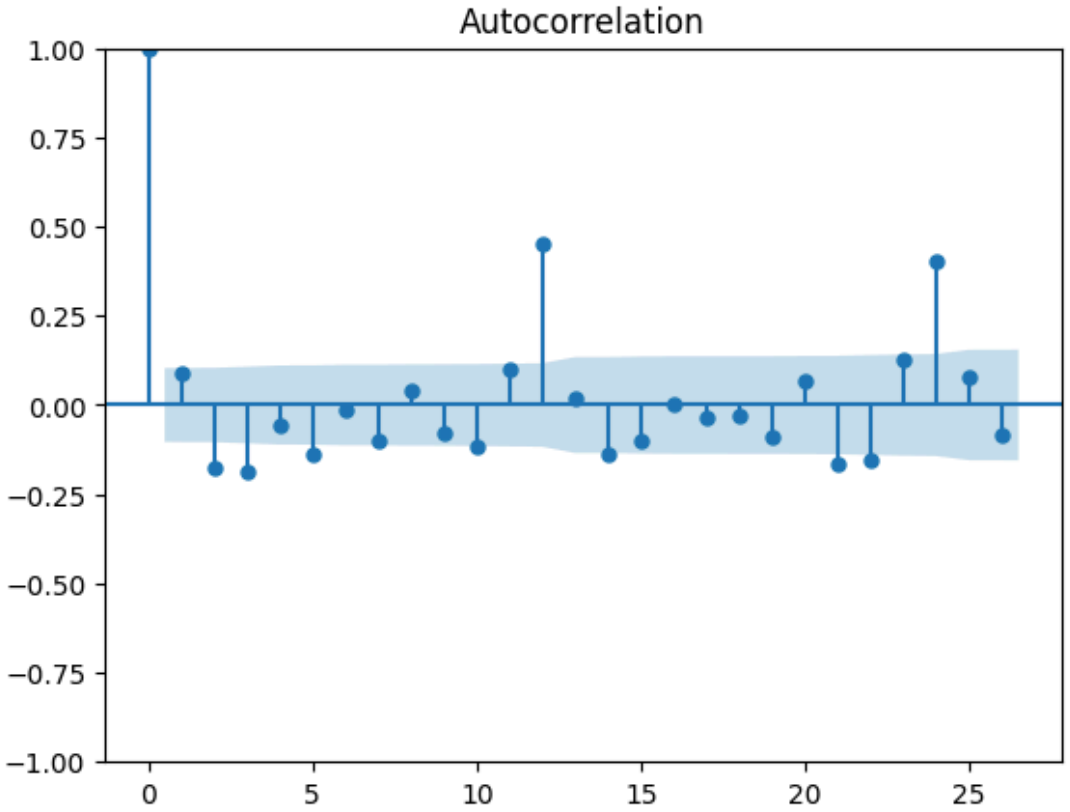

où les soupçons de saisonnalité refont surface, grâce aux corrélations à 12 et 24 décalages (notamment sur l'ACF du FP). Malgré cela, l'analyse ne prendra pas en compte cette saisonnalité (en tant que contenu hors du périmètre du projet).

Ensuite, les ordres du VAR doivent être sélectionnés, pour lesquels le tableau suivant a été construit :

lags	AIC	BIC	FPE	HQIC
0	0.01963	0.04235	1.020	0.02869

lags	AIC	BIC	FPE	HQIC
1	-0.8031	-0.7350	0.4479	-0.7760
2	-0.8961	-0.7825	0.4081	-0.8508
3	-0.9866	-0.8276*	0.3728	-0.9232
4	-1.003	-0.7981	0.3669	-0.9211
5	-1.009	-0.7593	0.3645	-0.9096
6	-1.009	-0.7139	0.3645	-0.8915
7	-1.057	-0.7160	0.3476	-0.9210
8	-1.049	-0.6625	0.3504	-0.8948
9	-1.114	-0.6825	0.3283	-0.9421
10	-1.243	-0.7659	0.2886	-1.053
11	-1.233	-0.7101	0.2916	-1.024
12	-1.370	-0.8021	0.2542	-1.144*
13	-1.378	-0.7645	0.2523	-1.133
14	-1.388	-0.7296	0.2497	-1.126
15	-1.373	-0.6688	0.2536	-1.092
16	-1.371	-0.6211	0.2542	-1.072
17	-1.358	-0.5624	0.2577	-1.041
18	-1.348	-0.5076	0.2601	-1.013
19	-1.347	-0.4605	0.2607	-0.9934
20	-1.329	-0.3974	0.2654	-0.9576
21	-1.359	-0.3823	0.2576	-0.9698
22	-1.397	-0.3748	0.2481	-0.9897
23	-1.389	-0.3207	0.2504	-0.9629
24	-1.399*	-0.2857	0.2479*	-0.9552

Le nombre de décalages à utiliser a été choisi à 12, au vu du plateau relatif de l'AIC et du FPE, et de l'optimalité par rapport au HQIC. La différence de BIC n'est pas significative.

Ensuite, le VAR a été ajusté et les p-values obtenues. Ces valeurs sont détaillées dans le tableau suivant :

	FP	ASFP
const	9.817262e-01	9.595375e-01
L1.FP	4.324361e-05	3.578963e-02
L1.ASFP	4.313964e-01	1.262010e-08

	FP	ASFP
L2.FP	7.845107e-09	3.572106e-01
L2.ASFP	9.769884e-01	5.238548e-02
L3.FP	7.752250e-10	5.141585e-01
L3.ASFP	1.622765e-01	6.872779e-01
L4.FP	5.687943e-12	3.940452e-02
L4.ASFP	1.698324e-01	1.350943e-02
L5.FP	2.451409e-10	1.950322e-02
L5.ASFP	1.563796e-01	6.509347e-01
L6.FP	7.178461e-06	5.280860e-01
L6.ASFP	5.758835e-01	8.047216e-01
L7.FP	7.065265e-05	2.079919e-03
L7.ASFP	5.316309e-01	2.884829e-02
L8.FP	9.834851e-04	5.961535e-01
L8.ASFP	9.798318e-01	5.960105e-01
L9.FP	3.150002e-01	1.267059e-01
L9.ASFP	1.581907e-01	5.588873e-01
L10.FP	6.882874e-01	9.693582e-01
L10.ASFP	1.680526e-01	2.298063e-01
L11.FP	5.771115e-01	5.413738e-01
L11.ASFP	7.567492e-01	1.250017e-01
L12.FP	4.545992e-11	9.590485e-01
L12.ASFP	2.917952e-01	7.624610e-17

Pour mieux apprécier les significances, une carte de chaleur (*heatmap*) (0 si non significatif, 1 si significatif) a été construite :

où la tendance des aliments hors produits frais semble influencer les produits frais, mais pas autant l'inverse. Pour étudier cette relation, un test de causalité sera réalisé ci-dessous, mais au préalable les modules des inverses des racines doivent être considérés :

root	module
0	1.196186
1	1.196186
2	1.147271
3	1.147271
4	1.112399
5	1.112399
6	1.086946
7	1.086946
8	1.074866
9	1.074866
10	1.070731
11	1.070731
12	1.068290
13	1.068290
14	1.064753

root	module
15	1.064753
16	1.063729
17	1.063729
18	1.056891
19	1.056891
20	1.040010
21	1.040010
22	1.036002
23	1.036002

d'où l'on conclut que le processus VAR est stationnaire et stable. Finalement, le déterminant de Omega MLE est 0.0207.

Finalement, le tableau des p-values du test de causalité est le suivant (les valeurs C_{ij} signifient que i cause j) :

	ASFP	FP
ASFP	0.00	0.29
FP	0.02	0.00

ce qui met en évidence le comportement supposé ci-dessus : les produits non frais causent un effet sur les produits frais, mais l'inverse n'est pas le cas.

Ensuite, les réponses aux chocs ont été étudiées :

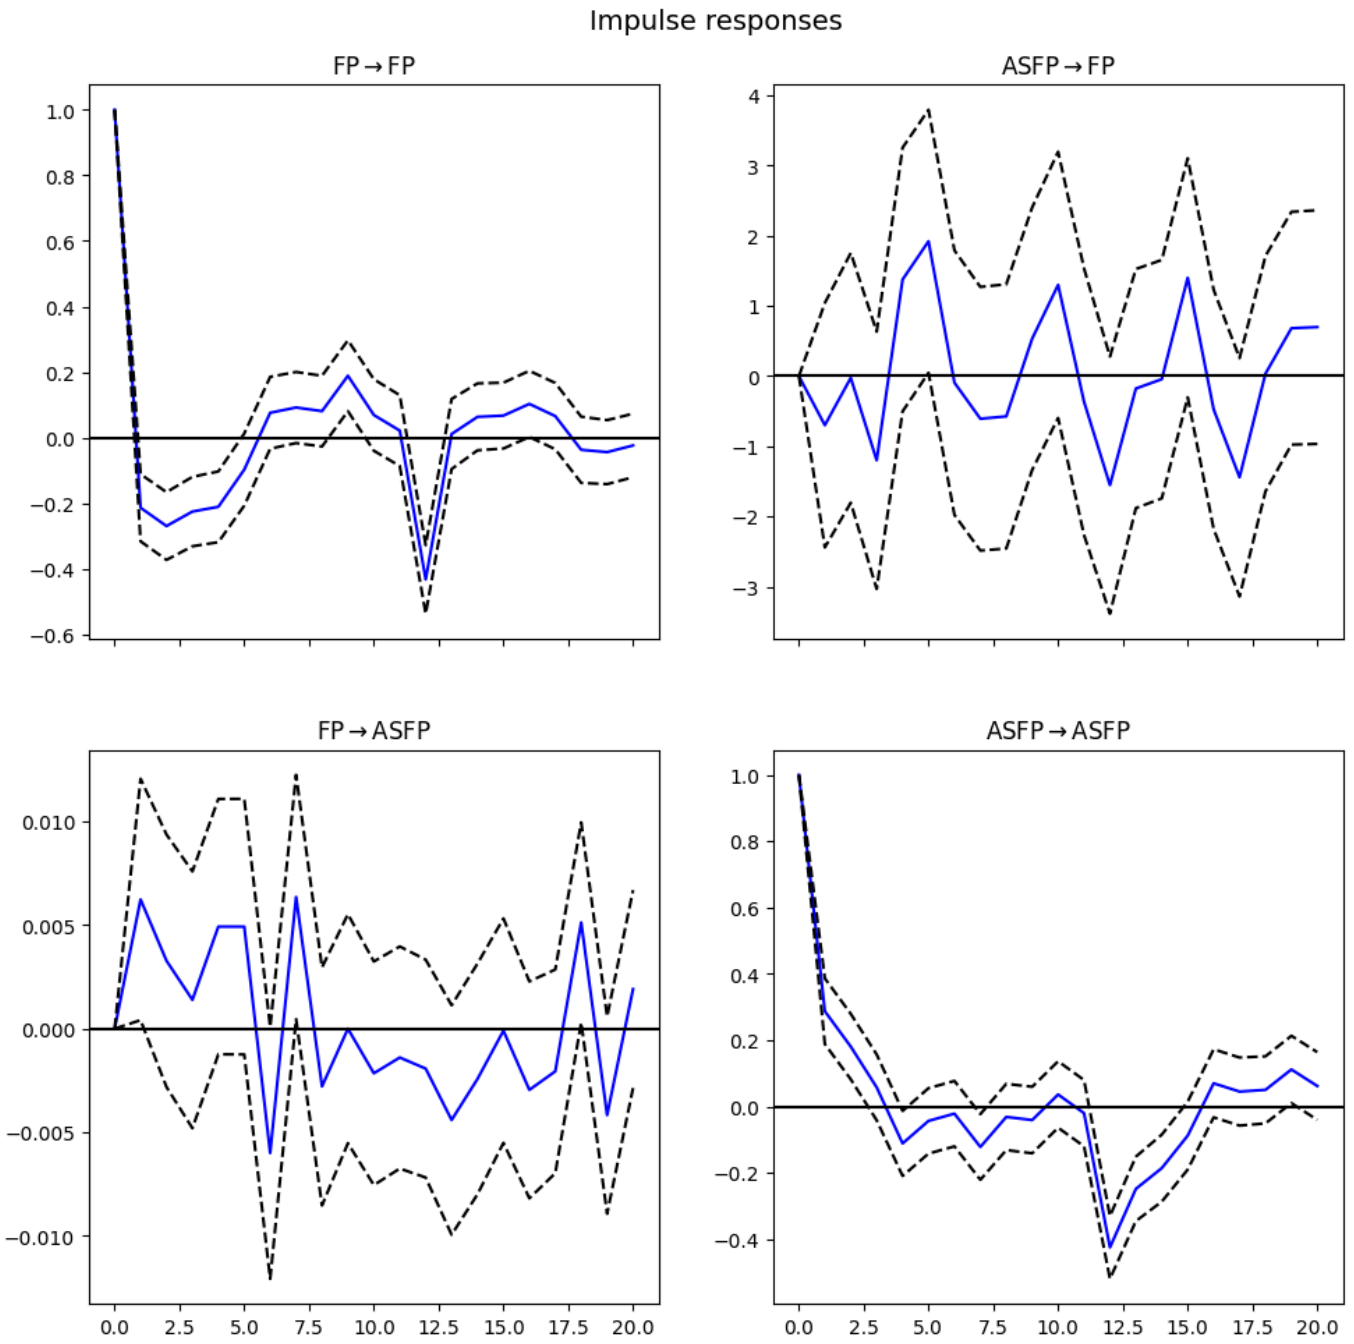

Les chocs des variables sur elles-mêmes semblent s'éteindre après une réversion temporaire avant de s'approcher de zéro. Ce phénomène n'est pas trop étonnant, même s'il montre une certaine volatilité. Néanmoins, les effets de l'ASFP montrent une relation faible ou instable, qui n'est pas robuste statistiquement, ce qui pourrait indiquer que la relation est plutôt produite du bruit qu'une relation réelle. Ce comportement est également observé pour la relation inverse, ce qui pourrait témoigner d'une relation très faible entre les variables.

Coïntégration

Pour la conïntégration, il faut tout d'abord faire un test de coïntégration: le test de Johansen. Les valeurs obtenus sont montrées ci-dessous:

r (H0)	trace statistic (lr1)	CV 90%	CV 95%	CV 99%	Decision (95%)
r = 0	216.6072	13.4294	15.4943	19.9349	Rejette H0
r ≤ 1	27.7778	2.7055	3.8415	6.6349	Rejette H0

Ceci montre que $r=2$, ce qui montre un régime de rang complet, ce qui montre qu'il n'y a pas de racines unitaires et que les séries sont $I(0)$ -raissonable, en vue des résultats précedentes -, ce qui ne correspod pas au cas de coïntégration, plutôt un de VAR (éventuellement aux niveaux). Malhereussement, il n'y a pas d'évidence de l'eficacité de ce modèle.

Conclusion

L'étude de la variation mensuelle de l'IPC en France métropolitaine sur la période 1996–2025 a permis de mettre en évidence plusieurs propriétés structurelles de la série. D'abord, l'analyse descriptive a montré une distribution proche de la gaussienne, sans tendance ni saisonnalité apparente, avec une autocorrélation faible et à court terme. Ces caractéristiques ont orienté naturellement la modélisation vers un cadre ARMA.

Parmi les spécifications testées, le modèle ARMA(1,1) s'est imposé selon les critères AIC et BIC, avec des résidus compatibles avec l'hypothèse de bruit blanc — confirmée par le test de Ljung-Box. L'analyse GARCH a ensuite révélé la présence d'effets de volatilité conditionnelle dans les résidus du modèle ARMA, mieux capturés par une distribution t de Student que par une gaussienne, avec $\nu \approx 5.2$. Le test LM a confirmé que le phénomène GARCH, bien présent dans les résidus ARMA, a été correctement absorbé par le modèle combiné. La stationnarité de la série a été vérifiée de façon robuste par le test ADF sous plusieurs spécifications de tendance, écartant définitivement l'hypothèse de racine unitaire.

L'analyse multivariée par modèle VAR(12) sur les variations des aliments hors produits frais (ASFP) et des produits frais (FP) a permis de mettre en évidence une relation causale asymétrique au sens de Granger : l'ASFP influence significativement le FP, mais l'inverse n'est pas vérifié. Les réponses impulsionnelles, bien que traduisant une certaine instabilité à court terme, semblent cohérentes avec cette asymétrie. Enfin, le test de Johansen a indiqué un rang de coïntégration complet ($r=2$), ce qui confirme que les deux séries sont $I(0)$ et qu'un modèle VAR aux niveaux est approprié — l'approche VECM n'ayant pas de justification dans ce cas.

En perspective, il pourrait être pertinent de traiter explicitement la saisonnalité du FP, visible dans ses fonctions d'autocorrélation, ainsi que d'explorer des spécifications SARIMA ou des modèles à facteurs pour mieux rendre compte de la dynamique commune entre les groupes de produits.

Anexe: Code

Les codes utilisés pour ce projet ont été ajoutées au fichier zip, mais les données, à cause de leur taille, n'ont pas été ajoutées. Néanmois, ils sont facilement accesibles grâce au lien dans l'introduction.

Les codes sont à utiliser de la façon suivante: le code 'get_data.py' processe les données pour le modèle ARMA: car_ipc.csv. Ensuite, le code ARMA ajuste des modèles ARMA avec une méthode robuste pour obtenir des tableaux avec les valeurs tel que le p-value, l'AIC et le BIC.

Ensuite, pour l'analyse de ces resultat, le notebook univarie.ipynb est utilisé, ainsi que le modèle GARCH, d'où son nom. Pour les modèles multivariés le notebook multivarie.ipynb a été utilisé pour le création et l'analyse des méthodes multivariées: VAR et CI.

Finalement, plusieurs fichiers csv on été crées pour l'analyse et la sauvegarde des résultats, ainsi que plusiers figures dans le dossier figures, utilisées pour la création de ce Rapport.